

МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования

**«САРАТОВСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИМЕНИ Н. Г. ЧЕРНЫШЕВСКОГО»**

Кафедра информатики и программирования

**СОЗДАНИЕ РЕКОМЕНДАТЕЛЬНОЙ СИСТЕМЫ ДЛЯ
ПРИЛОЖЕНИЯ ЗНАКОМСТВ**

БАКАЛАВРСКАЯ РАБОТА

студента 4 курса 441 группы
направления 02.03.03 — Математическое обеспечение и администрирование
информационных систем
факультета компьютерных наук и информационных технологий
Уталиева Султана Едильбаевича

Научный руководитель
ст.преп. кафедры ИиП

А. А. Казачкова

Заведующий кафедрой
к. ф.-м. н., доцент

Огнева М. В.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	3
1 Анализ предметной области и существующих решений	5
1.1 Особенности рекомендательных систем	5
1.2 Обзор рекомендательных систем в сфере онлайн-знакомств	5
1.3 Особенности сбора и представления пользовательских признаков ..	12
2 Методы построения рекомендательной системы	14
2.1 Коллаборативная фильтрация	14
2.2 Контентная фильтрация	15
2.3 Эвристики: совпадения по ответам, популярность, фильтры	16
2.4 Применение кластеризация (k-means, DBSCAN) в рекомендациях ..	17
2.5 Стратегии холодного старта	19
2.6 Методы глубокого обучения в рекомендательных системах	20
2.7 Гибридные подходы	22
2.8 Методы оценки рекомендательной системы в приложении знакомств	24
3 Теоретические основы разработки мобильных приложений	26
3.1 Общие особенности мобильной разработки	26
3.2 Общие подходы к проектированию мобильных систем	27
3.3 Клиент-серверная архитектура	28
3.4 Безопасность и конфиденциальность	29
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	31

ВВЕДЕНИЕ

В последние годы наблюдается устойчивый рост интереса к персонализированным цифровым сервисам, что обусловлено стремлением пользователей получать релевантный контент и улучшенный пользовательский опыт. Одним из ключевых инструментов, обеспечивающих персонализацию в цифровых продуктах, являются рекомендательные системы — интеллектуальные алгоритмы, позволяющие адаптировать предложения под индивидуальные предпочтения. Их значение особенно возрастает в мобильных приложениях для знакомств, где качество рекомендаций напрямую влияет на успешность социальных взаимодействий и удовлетворённость пользователей [1, 2].

Наиболее известные приложения в этой сфере, такие как Tinder, OkCupid и Hinge, внедряют продвинутые алгоритмы рекомендаций, включая коллаборативную фильтрацию, обучение представлений и гибридные подходы, часто опирающиеся на крупномасштабные данные и модели машинного обучения [3–5]. Однако многие из этих решений слабо адаптированы к ситуациям, где наблюдается дефицит данных — например, на ранних этапах использования или в условиях добровольного предоставления информации пользователями [6, 7].

В данной работе рассматривается задача построения рекомендательной системы для мобильного приложения знакомств. В отличие от большинства существующих решений, рекомендации в предлагаемой системе формируются не только на основе анкетных данных, но и на основе тестов-опросов, которые пользователь может проходить по желанию. Каждая карточка с вопросом предоставляет возможность ответить «да», «нет» или пропустить, что позволяет формировать тернарные признаки $(-1, 0, 1)$, лежащие в основе профиля предпочтений.

Целью дипломной работы является разработка рекомендательной системы, обеспечивающей релевантные и разнообразные рекомендации потенциальных партнёров на основе результатов тестирования. Для достижения этой цели решаются следующие задачи:

- анализ существующих подходов к построению рекомендательных систем в контексте дейтинг-приложений;
- формализация задачи рекомендаций с учётом специфики представления пользовательских признаков;
- проектирование и реализация архитектуры рекомендательной системы;

- исследование методов контентной фильтрации и эвристик для генерации рекомендаций;
- разработка подхода к оценке качества рекомендаций с использованием оффлайн-метрик.

Практическая значимость работы заключается в создании масштабируемого и интерпретируемого рекомендательного решения, подходящего для использования в условиях ограниченных вычислительных ресурсов и высокой динамики пользовательских предпочтений.

1 Анализ предметной области и существующих решений

1.1 Особенности рекомендательных систем

Рекомендательные системы являются неотъемлемой частью современных цифровых платформ, предоставляя пользователям персонализированные предложения продуктов, услуг или контента. Они находят широкое применение в различных областях, включая электронную коммерцию, стриминговые сервисы, социальные сети и онлайн-знакомства.

Современные рекомендательные сталкиваются с рядом проблем:

- отсутствие информации о новых пользователях и объектах (проблема холодного старта) [6];
- высокая разреженность пользовательско-объектных матриц [1];
- необходимость обеспечения справедливости и отсутствия предвзятости в рекомендациях [2].

Современные исследования направлены на преодоление этих ограничений, в том числе с использованием больших языковых моделей, методов объяснимого машинного обучения и расширения пользовательского контекста.

1.2 Обзор рекомендательных систем в сфере онлайн-знакомств

Онлайн-сервисы знакомств предъявляют особые требования к алгоритмам рекомендаций. Поскольку конечной целью является установление реального или виртуального контакта между людьми, системы должны максимально точно учитывать совместимость по широкому спектру признаков, при этом оставаясь достаточно лёгкими в вычислении и объяснимыми.

1.2.1 OkCupid

Платформа OkCupid применяет нетривиальный подход к построению рекомендаций, фокусируясь на глубоком анализе анкет пользователей и их ответов на вопросы. В отличие от многих систем, которые ориентируются лишь на поведение пользователей, OkCupid делает упор на содержательные признаки совместимости.

Пользователи проходят опросы, отвечая на вопросы о ценностях, привычках, интересах и взглядах. Для каждого вопроса пользователь:

- указывает свой собственный ответ;
- выбирает приемлемые для него ответы потенциального партнёра;
- определяет важность соответствия по этому вопросу.

Таким образом, для каждого пользователя можно получить богатый профиль предпочтений, включающий не только их мнения, но и ожидания от других.

Основой рекомендательной системы OkCupid служит собственная метрика совместимости, вычисляемая по формуле, напоминающей обобщённую версию взвешенного совпадения. Пусть пользователь A ответил на n вопросов, по которым можно сопоставить ответы с пользователем B . Тогда их совместимость вычисляется по следующей схеме:

1. Для каждого вопроса i определяется s_i^A — совпадает ли ответ B с приемлемыми ответами A ; w_i^A — важность вопроса по мнению A .
2. Вычисляется доля удовлетворения B ожиданий A :

$$S_{AB} = \frac{\sum_{i=1}^n s_i^A \cdot w_i^A}{\sum_{i=1}^n w_i^A}$$

3. Аналогично считается S_{BA} .
4. Итоговая совместимость:

$$C(A, B) = \sqrt{S_{AB} \cdot S_{BA}}$$

Такой симметричный подход позволяет учитывать желания обеих сторон, что особенно важно в сфере знакомств [8].

Кроме ответов на вопросы, система также может учитывать:

- географическое положение пользователей;
- возраст и пол;
- поведенческие метрики (например, активность и отклики);
- интересы, указанные в профиле;
- алгоритмы коллаборативной фильтрации на основе лайков.

Однако основным источником данных остаются именно опросы, что выгодно отличает OkCupid от других платформ.

Рекомендательная система OkCupid строится на принципах симметричной оценки, учитывающей как личные предпочтения, так и взаимные ожидания. Модель сочетает элементы экспертных систем и идеи коллаборативной фильтрации, что позволяет выдавать персонализированные рекомендации, основанные на содержательных признаках [3].

Тем не менее, использование опросов как основной основы для рекомендаций имеет ряд ограничений:

- Самоотчетность. Пользователи могут отвечать неискренне, выбирая социально одобряемые ответы или предполагаемые предпочтения других, а не собственные.
- Ограниченность охвата. Даже при большом числе вопросов многие аспекты личности, поведения и совместимости остаются неохваченными.
- Неполные профили. Пользователи часто не отвечают на все доступные вопросы, что затрудняет построение точных рекомендаций.
- Фиксированные веса. Веса важности выставляются вручную, и пользователь может переоценить или недооценить значимость отдельных тем.
- Изменчивость во времени. Ответы могут устаревать, но система не всегда способна учитывать динамику изменения взглядов и предпочтений.

Таким образом, хотя подход OkCupid обладает значительной выразительной силой, его эффективность может снижаться при недостаточной мотивации пользователей честно и подробно заполнять анкету.

1.2.2 Tinder

Платформа Tinder делает акцент на скорости взаимодействия и минимализме в пользовательском интерфейсе. Это определяет и архитектуру рекомендательной системы: она почти полностью основана на поведенческих данных, а не на заранее структурированных опросах [9].

Рекомендации Tinder опираются на наблюдение за действиями пользователя в реальном времени, применяя идеи из области ранжирования, коллаборативной фильтрации и машинного обучения.

- Пользователь не заполняет анкету или тесты – основным источником сигналов становится поведение (свайпы, матчи, отклики).
- Цель системы – ранжировать потенциальных партнёров по вероятности положительного отклика.
- Взаимная симпатия (мэтч) служит основной меткой релевантности.

Ранее Tinder применял модификацию рейтинговой системы Elo, аналогичной той, что используется в шахматах. Каждому пользователю приписывался скрытый рейтинг R , который обновлялся при каждой паре действий:

$$R_A^{\text{new}} = R_A + K \cdot (S - E)$$

где:

- S — фактический результат (1, если A получил лайк от B , 0 — если дизлайк);
- E — ожидаемая вероятность положительного отклика, например:

$$E = \frac{1}{1 + 10^{(R_B - R_A)/400}}$$

- K — коэффициент обучения.

Со временем эта система была признана слишком статичной и неспособной учитывать сложные паттерны предпочтений.

В настоящее время Tinder использует более гибкий и масштабируемый подход на основе моделей обучения ранжированию и нейронных сетей. Ключевые особенности [5]:

1. Использование исторических свайпов как обучающего датасета.
2. Обогащение признаков за счёт:
 - времени суток, геолокации, возраста и пола;
 - информации о взаимодействиях (ответы в чатах, продолжительность общения);
 - изображений (модели компьютерного зрения извлекают визуальные эмбединги).
3. Применение моделей типа learning-to-rank, включая градиентный бустинг и глубокие нейросети.
4. Возможное использование sequence-based моделей (например, RNN или трансформеров), учитывающих порядок свайпов.

Хотя такой подход даёт хорошее качество персонализации, он не лишён ограничений:

- Холодный старт. Новым пользователям сложно получить релевантные рекомендации до накопления истории свайпов.
- Смещение данных. Пользователи чаще свайпают по привлекательности, а не по глубинной совместимости.
- Неустойчивость. Поведение может быть ситуативным, но алгоритм воспринимает его как предпочтение.
- Мало объяснимости. Модель сложно интерпретировать или объяснить пользователю, почему показан тот или иной профиль.

Модель рекомендаций Tinder эволюционировала от простой системы рейтингов к сложной системе поведенческого ранжирования. Она эффективно мас-

штабируется и адаптируется под предпочтения пользователя, но при этом страдает от отсутствия прозрачности и возможной поверхностности критериев совместимости [10].

1.2.3 Hinge

Платформа Hinge позиционирует себя как сервис для «удаления» приложения после нахождения подходящего партнёра. Это отражается и в её подходе к построению рекомендаций: модель ориентирована не на максимум свайпов, а на вероятность качественного взаимодействия. Рекомендательная система Hinge учитывает как поведенческие сигналы, так и контекстные данные, стремясь построить эффективные персонализированные предложения.

В основе лежат несколько ключевых принципов:

- Система стремится обучаться на успешных взаимодействиях — прежде всего на лайках, приводящих к продолжительным диалогам.
- Учитывается не только сам факт лайка, но и качество последующего общения.
- Рекомендации строятся с использованием ранжирования, основанного на моделях типа learning-to-rank.

Ключевым источником вдохновения послужил алгоритм Gale–Shapley, использующийся в задаче стабильного брака. В оригинальной постановке каждый участник ранжирует партнёров, и цель — найти устойчивое соответствие. В адаптации Hinge этот принцип реализуется эвристически, через поиск так называемого «самого совместимого» партнёра дня, при этом система моделирует предпочтения обеих сторон [11].

Если обозначить:

- $P(u, v)$ — вероятность успешного взаимодействия между пользователями u и v ;
 - R_u — рейтинг, отражающий склонность u к взаимодействию с разными типами партнёров;
 - C_v — контекстные характеристики пользователя v ;
- то задача рекомендации может быть сведена к оценке:

$$\hat{y}_{uv} = f(R_u, C_v)$$

где f — обученная модель, приближающая вероятность успешного взаи-

модействия. Под успешностью понимается не просто лайк, а наличие значимого чата или повторного контакта.

Кроме основных моделей, в системе используются дополнительные эвристики:

- подавление повторяющихся шаблонов (например, слишком частые лайки одному типу);
- учёт предпочтений по контенту профиля (фото, ответы на подсказки);
- отслеживание реакций на предложенные анкеты и их отложенное влияние.

Важной частью рекомендаций Hinge является система подбора пары дня. Она основывается на анализе двусторонних предпочтений, активности и недавнего поведения. Рекомендуемый партнёр имеет высокий прогнозируемый шанс на взаимную симпатию и заинтересованный диалог.

Несмотря на успех такой модели, она имеет определённые ограничения:

- зависимость от истории пользователя, что создаёт проблему холодного старта;
- возможные локальные оптимумы: пользователь может застревать в узком профиле предложений;
- невысокая прозрачность — пользователю сложно понять, почему предложен тот или иной контакт.

В отличие от Tinder, Hinge делает ставку не на частоту свайпов, а на глубину взаимодействий. Это требует от системы учёта более сложных поведенческих метрик, включая динамику общения после совпадения. Такой подход требует более тонкой настройки, но лучше отвечает цели платформы — формированию устойчивых связей [4].

1.2.4 eHarmony

Рекомендательная система eHarmony изначально создавалась как экспертная модель совместимости, основанная на глубоком психологическом тестировании. Платформа ориентирована на долгосрочные отношения, а не на быстрые знакомства. Это определяет как архитектуру системы, так и методологию сбора и обработки данных.

В отличие от более поведенчески-ориентированных платформ, eHarmony делает ставку на анкеты, основанные на психологической типологии. При регистрации каждый пользователь заполняет обширную анкету, содержащую от 100 до 150 вопросов, касающихся:

- личностных черт (экстраверсия, добросовестность, невротизм и др.);
- ценностей и жизненных установок;
- отношения к конфликтам, компромиссам, религии и карьере;
- предпочтений в партнёрстве и стиле общения.

Из ответов формируется вектор признаков $x \in \mathbb{R}^d$, где d — число выделенных латентных характеристик. Далее используется модель оценки совместимости между двумя пользователями u и v на основе расстояния между их признаковыми векторами:

$$S(u, v) = 1 - \frac{\|x_u - x_v\|}{D}$$

где D — нормирующий коэффициент (максимально возможное расстояние), а $S(u, v)$ — мера совместимости, принимающая значения от 0 до 1.

Алгоритм может включать дополнительные поправки:

- усиление совпадений по наиболее значимым признакам;
- штрафы за критические несовпадения (например, по отношению к детям или религии);
- предпочтение партнёров, близких по возрасту, географии или культурному фону.

Система реализует фильтрацию на основе заранее определённой модели совместимости, а не обучения на пользовательском поведении. Это означает, что:

1. рекомендации стабильны во времени и не зависят от текущей активности;
2. пользователи получают небольшой, но тщательно отобранный список совпадений;
3. основной целью алгоритма является структурная совместимость, а не привлекательность.

Несмотря на высокую психологическую обоснованность, такой подход имеет ряд ограничений:

- высокая когнитивная нагрузка при регистрации, что отпугивает часть пользователей;
- отсутствие адаптации под поведение — система не обучается на реальных откликах;
- возможная переориентация на типаж, а не на реальное разнообразие предпочтений.

Тем не менее, eHarmony демонстрирует устойчивую эффективность в своей нише, благодаря глубокой проработке модели совместимости и ориентации на фундаментальные ценности и личностные черты. Такой подход хорошо подходит для пользователей, ищущих стабильные и продолжительные отношения [12].

1.3 Особенности сбора и представления пользовательских признаков

В рекомендательных системах, применяемых в онлайн-знакомствах, центральную роль играет сбор и интерпретация информации о предпочтениях пользователей. Эти данные служат основой для построения персонализированных профилей и определения потенциально совместимых кандидатов. Анализ существующих решений в данной предметной области выявляет два крайних подхода к сбору информации:

- длинные анкеты с детализированными вопросами, характерные для платформ вроде eHarmony, обеспечивают богатое представление о пользователе, но требуют значительных усилий при заполнении и приводят к высокой доле отказов;
- минималистичные интерфейсы типа Tinder предлагают быструю оценку по принципу свайпа пользователей, обеспечивая высокую конверсию, но теряя глубину предпочтений.

В качестве компромиссного решения рассматриваются тернарные опросы, в которых каждый вопрос допускает три варианта реакции: положительную, отрицательную и нейтральную. Это позволяет выразить отношение к различным характеристикам без излишней нагрузки. Каждый ответ кодируется значением $q_i \in \{-1, 0, 1\}$, где i — номер вопроса. Такая шкала обеспечивает:

- компактность векторного представления профиля;
- возможность учитывать отсутствие чёткой позиции;
- поддержку различных методов машинного обучения и заполнения пропусков.

Результаты сбора формируются в разреженную матрицу $R = (q_{u,i})$, где u — пользователь, i — вопрос, а $q_{u,i}$ — реакция. Пропущенные значения соответствуют отсутствию взаимодействия. На практике возможно использование стратегий заполнения: нулями, средним значением по вопросу, либо построение модели, устойчивой к разреженности.

В дополнение к ответам могут быть включены и другие признаки:

- демографические данные — возраст (нормированный), пол (бинарная переменная);
- описания «о себе», конвертируемые в эмбединги с помощью языковых моделей;
- временные характеристики — длительность прохождения, количество пропусков, уверенность в ответах.

Особенность предметной области знакомств заключается в том, что каждый пользователь является одновременно субъектом и объектом рекомендаций. Это накладывает дополнительные требования к симметричности представлений и способности учитывать двустороннюю заинтересованность. Более того, успешность рекомендации здесь не сводится к лайку, а может быть оценена через цепочку взаимодействий: переписка, ответный интерес, встречи.

На этапе анализа задач были также выявлены следующие характеристики, которые следует учитывать при проектировании системы:

- необходимость работать с разреженными признаковыми матрицами и отсутствием части информации;
- поддержка холодного старта для новых пользователей и вопросов;
- ориентация на сравнение пользователей между собой, а не на ранжирование объектов фиксированной природы.

Таким образом, представление предпочтений в тернарной форме, дополненное демографией и эмбедингами, формирует универсальную основу для построения профилей. Эти профили могут использоваться в различных методах рекомендации — от коллаборативной фильтрации до кластеризации и нейросетевых моделей.

2 Методы построения рекомендательной системы

2.1 Коллаборативная фильтрация

Коллаборативная фильтрация является одним из наиболее популярных подходов в рекомендательных системах, особенно в условиях, когда отсутствует явное описание объектов или пользователей. Основная идея заключается в том, что предпочтения пользователей могут быть предсказаны на основе поведения других пользователей с похожими вкусами.

Существует два основных типа коллаборативной фильтрации: на основе памяти (memory-based) и на основе модели (model-based). Первый подход использует метрики сходства между пользователями или объектами (например, косинусное расстояние, корреляцию Пирсона) и агрегирует оценки соседей. Второй — строит параметризованную модель на основе данных о взаимодействиях, чаще всего через факторизацию матрицы.

Пусть имеется матрица взаимодействий $R \in \mathbb{R}^{m \times n}$, где m — количество пользователей, n — количество объектов (например, анкет потенциальных партнёров). Элемент $r_{u,i}$ может обозначать бинарную оценку (лайк/не лайк), числовой рейтинг или иной сигнал предпочтения. Коллаборативная фильтрация предполагает, что в матрице присутствует скрытая структура, отражающая закономерности во вкусах пользователей [13].

Одним из распространённых методов является сингулярное разложение (SVD) или его модификации (например, Funk-SVD, ALS), при которых R аппроксимируется как

$$R \approx UV^T,$$

где $U \in \mathbb{R}^{m \times k}$ и $V \in \mathbb{R}^{n \times k}$ содержат латентные векторы пользователей и объектов соответственно, а k — число латентных признаков. Значение $\hat{r}_{u,i} = U_u \cdot V_i^T$ интерпретируется как предсказанная степень интереса пользователя u к объекту i .

Интересным обобщением является применение коллаборативной фильтрации к данным не только о лайках, но и о признаках, таких как ответы пользователей на опросы. В этом случае каждый пользователь представлен тернарным или категориальным вектором, а матрица $Q \in \{-1, 0, 1\}^{m \times p}$ (где p — число вопросов) также может быть факторизована аналогичным способом:

$$Q \approx U'Z^T.$$

Полученные векторы могут использоваться для оценки схожести между пользователями, для восстановления пропущенных ответов или как источник признаков для гибридных моделей.

Коллаборативная фильтрация демонстрирует высокую эффективность при наличии большого количества пользовательских взаимодействий, однако страдает от проблемы холодного старта и может усиливать популярность одних и тех же объектов, снижая разнообразие рекомендаций [7].

2.2 Контентная фильтрация

Контентная фильтрация представляет собой один из классических подходов к построению рекомендательных систем. Основная идея заключается в том, чтобы рекомендовать объекты, схожие с теми, которые пользователь оценил положительно ранее, основываясь на характеристиках самих объектов. В отличие от коллаборативной фильтрации, здесь не учитываются предпочтения других пользователей.

Каждый объект описывается вектором признаков, которые могут быть бинарными, числовыми или категориальными. Пусть объект j представлен вектором признаков $x_j \in \mathbb{R}^d$. Модель пользователя строится как агрегированное представление объектов, с которыми у него были положительные взаимодействия. Например, если пользователь i взаимодействовал с объектами j_1, \dots, j_k , то вектор предпочтений можно получить как среднее:

$$p_i = \frac{1}{k} \sum_{s=1}^k x_{j_s}.$$

Рекомендации формируются на основе сходства между вектором предпочтений пользователя и векторами новых объектов. Чаще всего используется косинусное расстояние:

$$\text{sim}(p_i, x_j) = \frac{p_i^\top x_j}{\|p_i\| \cdot \|x_j\|}.$$

Объекты с наибольшим значением sim включаются в топ рекомендаций [14].

Данный подход имеет ряд достоинств:

- высокая интерпретируемость: можно объяснить, почему был рекомендован тот или иной объект;

- независимость от количества других пользователей;
- устойчивость к проблеме холодного старта для объектов (если их описание доступно).

Однако контентная фильтрация имеет и ограничения:

- рекомендации ограничиваются областью уже проявленных интересов;
- трудно учитывать сложные зависимости между признаками;
- качество зависит от полноты и выразительности признакового описания.

Для повышения гибкости могут применяться методы машинного обучения. Например, обучающая выборка может включать пары (x_j, y_{ij}) , где y_{ij} — бинарная переменная, указывающая наличие положительного отклика со стороны пользователя i на объект j . На этой основе можно обучить логистическую регрессию, SVM или градиентный бустинг, предсказывающий вероятность интереса к новому объекту.

Также возможны гибридные модели, объединяющие контентную и коллаборативную фильтрацию. Например, контентные признаки могут использоваться для регуляризации матричной факторизации или служить входом для нейронных сетей. Такие подходы позволяют улучшить обобщающую способность модели и преодолеть узость интересов, характерную для чисто контентной фильтрации [15].

Контентные методы особенно полезны в системах, где объекты имеют чётко выраженные признаки: тексты, категории, изображения, ответы на тесты или анкеты. При наличии информативного описания они позволяют получать рекомендации уже на самых ранних этапах использования системы, что делает их важным компонентом гибридных решений.

2.3 Эвристики: совпадения по ответам, популярность, фильтры

Эвристические методы в рекомендательных системах основаны на наборе простых правил и предположений, позволяющих быстро и эффективно формировать рекомендации. Несмотря на относительную простоту, такие подходы остаются актуальными, особенно в условиях ограниченности данных или требований к объяснимости.

Одним из базовых эвристических подходов является сравнение пользователей по их ответам на вопросы анкет или опросов. Если ответы представлены в тернарной шкале (например, -1 — несогласие, 0 — нейтрально, 1 — согласие), то схожесть между пользователями можно оценить по доле совпадающих

ответов:

$$\text{sim}(u, v) = \frac{1}{|P|} \sum_{i \in P} (q_{u,i} = q_{v,i}),$$

где P — множество вопросов, на которые оба пользователя дали ответ. Этот подход применим как в системах знакомств, так и в других областях, где важна совместимость взглядов, предпочтений и интересов.

Другим эвристическим приёмом является использование показателя популярности. Объекты (например, профили или товары), получившие наибольшее количество положительных оценок, могут предлагаться новым пользователям в качестве стартовых рекомендаций. Популярность может быть нормирована, например:

$$\text{pop}(i) = \frac{\text{число лайков объекта } i}{\text{максимальное число лайков среди всех объектов}}.$$

Популярные рекомендации часто дополняются фильтрацией по демографическим и другим признакам, таким как возраст, пол, географическое местоположение, язык, наличие общих интересов и т. д [16].

Такие фильтры применяются до или после основного ранжирования и позволяют исключить очевидно нерелевантные варианты. Например, пользователь, заинтересованный только в кандидатах определённого возраста или пола, должен получать только соответствующие предложения.

Также может применяться эвристика совпадения по ключевым признакам. Если в профиле пользователя указаны предпочтения (например, любимые фильмы, занятия, взгляды), система может искать совпадения с другими профилями и ранжировать их по количеству совпавших интересов.

Комбинирование эвристик позволяет построить гибкую систему, способную адаптироваться к условиям отсутствия данных, начальной загрузки, а также повысить обоснованность рекомендаций. При этом эвристические методы легко интерпретируемы, что важно в чувствительных сферах, таких как онлайн-знакомства или подбор персонала.

2.4 Применение кластеризация (k-means, DBSCAN) в рекомендациях

Кластеризация — это метод обучения без учителя, направленный на группировку объектов в кластеры таким образом, чтобы элементы одного кластера были похожи друг на друга и отличались от элементов других кластеров. В

контексте рекомендательных систем кластеризация применяется для:

- сегментирования пользователей (или объектов) по интересам, поведению или признакам;
- повышения масштабируемости рекомендаций за счёт ограничения поиска релевантных кандидатов внутри кластера;
- выявления нишевых предпочтений и персонализированных паттернов.

Одним из наиболее популярных алгоритмов является k -means. Он принимает на вход число кластеров k и итеративно минимизирует внутрикластерную дисперсию:

$$\sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - \mu_j\|^2,$$

где C_j — кластер, а μ_j — его центр. Алгоритм эффективен при компактных и сферических кластерах, но чувствителен к выбору k и неустойчив к выбросам.

Для более гибкой кластеризации используется алгоритм DBSCAN. Он группирует точки по плотности: кластером считается связная по плотности область, где каждая точка имеет хотя бы $minPts$ соседей в пределах радиуса ε . DBSCAN способен находить кластеры произвольной формы и автоматически игнорирует шум (выбросы), что делает его особенно полезным в гетерогенных данных.

В рекомендательных системах кластеризация применяется по-разному:

- На пространстве пользователей: сегментация по поведенческим или опросным признакам позволяет формировать кластеры пользователей с похожими предпочтениями. Рекомендации для нового пользователя можно извлекать из наиболее близкого кластера.
- На пространстве объектов: группировка товаров, фильмов, анкет и пр. по тематике, стилю или целевой аудитории позволяет адаптировать рекомендации к интересам пользователя.
- В латентных пространствах: кластеризация векторов после факторизации (например, в SVD или autoencoder-подходах) даёт более сжатое и семантически значимое представление.

Кластеризация также применяется для визуализации и анализа структуры пользовательской базы, выявления целевых групп и построения тематических подборок. Её эффективность во многом зависит от выбора признаков и масштабов данных, поэтому нередко она используется в комбинации с другими

методами [17].

2.5 Стратегии холодного старта

Проблема холодного старта возникает, когда система не располагает достаточной информацией о пользователях или объектах, чтобы формировать персонализированные рекомендации. Выделяют два основных сценария: появление нового пользователя и добавление нового объекта (например, анкеты).

Для новых пользователей могут применяться следующие подходы:

- заполнение вступительных тестов или анкет — позволяет собрать первичные признаки и использовать их при формировании рекомендаций;
- использование демографических данных — рекомендации подбираются на основе поведения пользователей с аналогичными характеристиками (возраст, пол, география и т.д.);
- показ популярных объектов — временная стратегия, при которой пользователю демонстрируются анкеты с высокой оборачиваемостью, что помогает быстрее сформировать профиль предпочтений.

При появлении новых объектов, которые ещё не получили откликов, возможны такие меры:

- временное повышение приоритета в выдаче — например, показ новым или активным пользователям для ускоренного накопления статистики;
- использование признаков схожести — на основе анкетных данных, внешности (в случае CV), текста описания (в случае NLP) или ответов на вопросы;
- размещение в релевантных сегментах — объект может быть временно включён в выдачу по кластерам, в которые он потенциально попадает по признаковому пространству.

Кроме того, существуют универсальные стратегии, применимые и к новым пользователям, и к новым объектам:

- инициализация признаков с помощью доступных внешних данных — анкет, биографий, метаинформации;
- использование гибридных моделей, сочетающих элементы content-based и коллаборативной фильтрации — это снижает чувствительность к отсутствию истории;
- активное обучение — выбор контента, максимально полезного для уточнения предпочтений, что позволяет за минимальное число взаимодействий

улучшить качество рекомендаций.

Проблема холодного старта наиболее критична для систем, основанных на коллаборативной фильтрации, поскольку они требуют исторических данных о взаимодействии пользователей с объектами. Поэтому многие современные решения строятся с использованием дополнительных эвристик и предварительной инициализации признаков, что позволяет обеспечить устойчивость системы на ранних этапах использования [18].

2.6 Методы глубокого обучения в рекомендательных системах

Развитие нейросетевых архитектур оказало существенное влияние на область рекомендательных систем. Благодаря способности извлекать сложные латентные зависимости из разнородных данных, модели глубокого обучения применяются для повышения качества рекомендаций как в традиционных задачах (например, предсказание рейтингов), так и в более сложных сценариях, включая мультимодальные рекомендации, учет временной динамики и персонализацию на основе контекста.

Одним из первых направлений стало расширение классической матричной факторизации с помощью нейронных сетей. Вместо простой линейной факторизации матрицы взаимодействий $R \in \mathbb{R}^{m \times n}$, где m — количество пользователей, n — количество объектов, и R_{ij} — факт взаимодействия, используются обучаемые эмбединги и нелинейные функции активации. Примером такой модели является Neural Collaborative Filtering (NCF) [19]. В NCF пары эмбедингов (u_i, v_j) передаются через многослойный перцептрон:

$$\hat{r}_{ij} = \text{MLP}([u_i, v_j]),$$

где $[\cdot, \cdot]$ обозначает конкатенацию векторов. Модель обучается по функции потерь, например, бинарной кросс-энтропии в задаче предсказания лайка/дизлайка.

Другое направление связано с использованием рекуррентных и трансформерных архитектур для моделирования последовательности взаимодействий. Так называемые sequence-based recommenders учитывают порядок взаимодействий пользователя с объектами. Например, модель GRU4Rec применяет Gated Recurrent Unit (GRU) [20] для обработки истории действий пользователя. Базовая идея заключается в следующем: пусть x_1, x_2, \dots, x_T — последовательность

взаимодействий, тогда на каждом шаге рассчитывается скрытое состояние h_t :

$$h_t = \text{GRU}(x_t, h_{t-1}),$$

и предсказывается следующий элемент x_{t+1} с помощью softmax-слоя.

Для учёта более длинных зависимостей и параллельной обработки была предложена модель SASRec, основанная на механизме внимания. В отличие от рекуррентных моделей, здесь используется позиционно-кодированная последовательность эмбеддингов, проходящая через слои трансформера. Это позволяет учитывать контекст всех предыдущих действий при выборе следующей рекомендации [21].

Особое место занимают графовые нейронные сети, применяемые для моделирования взаимодействий в виде графов. В Graph Convolutional Matrix Completion [22], каждый пользователь и объект представляются вершинами, соединёнными ребром при наличии взаимодействия. Представления вершин обновляются по правилу:

$$h_i^{(l+1)} = \sigma \left(\sum_{j \in \mathcal{N}(i)} \frac{1}{c_{ij}} W^{(l)} h_j^{(l)} \right),$$

где $\mathcal{N}(i)$ — соседи вершины i , $W^{(l)}$ — матрица весов на l -м слое, c_{ij} — коэффициент нормализации. Такой подход позволяет учитывать структуру взаимодействий и взаимосвязь объектов, что особенно актуально для задач, где важны не только пользовательские предпочтения, но и социальные или контекстные связи.

Ещё одно активно развивающееся направление — мультимодальные рекомендации. Здесь помимо взаимодействий учитываются дополнительные признаки, такие как текст описания, изображения, аудио. Для обработки таких данных применяются CNN, BERT и другие специализированные архитектуры. В модели VBPR визуальные признаки изображений используются для расширения латентного пространства:

$$\hat{r}_{ij} = u_i^\top v_j + u_i^\top E x_j,$$

где x_j — визуальный вектор, полученный из изображения объекта, E — обучаемая матрица проекции [23].

Основные преимущества методов глубокого обучения:

- способность моделировать сложные нелинейные зависимости между пользователями и объектами;
- возможность использовать разнородные источники информации;
- высокая гибкость и расширяемость архитектур.

Тем не менее, существуют и ограничения:

- высокая требовательность к вычислительным ресурсам;
- потребность в большом объёме размеченных данных;
- трудность интерпретации и объяснимости результатов.

Таким образом, методы глубокого обучения открывают широкие перспективы для построения более точных и персонализированных рекомендательных систем, особенно в условиях, когда доступны дополнительные источники информации и достаточно ресурсов для обучения. Однако выбор таких подходов должен быть обоснован задачами проекта, размером аудитории и доступной инфраструктурой.

2.7 Гибридные подходы

Гибридные рекомендательные системы объединяют преимущества различных методов, включая коллаборативную фильтрацию, контентную фильтрацию и эвристические алгоритмы. Такая интеграция позволяет компенсировать слабые стороны отдельных подходов и достичь более высокой точности, устойчивости к холодному старту и разнообразия рекомендаций.

Существуют разные стратегии гибридизации:

- объединение выходов нескольких моделей (late fusion);
- комбинирование признаков на входе одной модели (early fusion);
- использование одного подхода в качестве фильтра, а другого — для ранжирования.

Один из классических примеров — модель, в которой одновременно учитываются схожесть пользователей (коллаборативная составляющая) и сходство объектов (контентная составляющая). Пусть r_{ui} — предсказанная оценка пользователя u для объекта i . Тогда комбинированная формула может иметь следующий вид:

$$r_{ui} = \alpha \cdot r_{ui}^{\text{collab}} + (1 - \alpha) \cdot r_{ui}^{\text{content}},$$

где r_{ui}^{collab} — предсказание по коллаборативной модели, r_{ui}^{content} — результат контентного ранжирования, а $\alpha \in [0, 1]$ — параметр, регулирующий вклад каждой части.

Другой подход основан на поэтапной фильтрации. Например, можно сначала применить контентную фильтрацию для предварительного отбора релевантных объектов, а затем выполнить коллаборативное ранжирование по пользовательским лайкам или оценкам. Такой двухшаговый процесс снижает вычислительную нагрузку и повышает релевантность [24].

Гибридные системы особенно полезны в следующих сценариях:

- наличие разреженной матрицы пользовательских взаимодействий, при этом имеются структурированные признаки объектов;
- необходимость рекомендаций для новых пользователей или новых объектов;
- желание учитывать не только историю взаимодействий, но и семантическое содержание;
- ориентация на объяснимость модели и возможность интерактивной настройки предпочтений.

В последние годы широкое распространение получили модели, встраивающие оба подхода в общую латентную структуру. Например, в модели Factorization Machines (FM) и её нейронных расширениях (Neural FM, DeepFM) признаки пользователей и объектов подаются в общий обучаемый слой, позволяющий учитывать как контентную, так и взаимодействующую информацию. Обозначим входной вектор признаков как x , тогда предсказание в FM-модели имеет вид:

$$\hat{y}(x) = w_0 + \sum_{i=1}^n w_i x_i + \sum_{i=1}^n \sum_{j=i+1}^n \langle v_i, v_j \rangle x_i x_j,$$

где v_i — латентный вектор i -го признака. Такая модель способна улавливать взаимодействия между признаками без явного задания структуры [25].

Гибридные методы на практике показывают высокую гибкость и адаптивность, особенно в условиях изменяющихся предпочтений и ограниченных пользовательских данных. Они успешно применяются в рекомендательных системах крупных платформ (Netflix, YouTube, LinkedIn), где важно сочетать поведенческие паттерны с контекстной и персонализированной информацией.

Совокупность перечисленных подходов делает гибридные методы универсальным инструментом, который можно адаптировать под особенности конкретной предметной области, в том числе в сфере онлайн-знакомств.

2.8 Методы оценки рекомендательной системы в приложении знакомств

Оценка качества рекомендательной системы в приложении знакомств играет ключевую роль для обеспечения релевантности и привлекательности предложений, предоставляемых пользователю. Цель такой оценки — убедиться, что система способствует установлению взаимного интереса и активному взаимодействию между пользователями.

В рамках мобильного приложения знакомств эффективность рекомендаций оценивается с двух сторон: на основе исторических данных (оффлайн) и в реальном времени (онлайн).

Оффлайн-оценка проводится до запуска системы на основе известных пользовательских взаимодействий. При этом выбирается контрольная выборка, в которой определённые события (например, взаимные лайки) скрываются, а алгоритм должен их предсказать. Основное внимание в данном случае уделяется метрике $\text{HitRate}@K$ — доле случаев, в которых хотя бы один релевантный объект оказался среди топ- K рекомендаций. Эта метрика отражает способность системы «попадать» в интересы пользователя и используется в качестве основной целевой метрики.

Также применяются следующие метрики:

- $\text{Precision}@K$ — доля релевантных пользователей среди K рекомендованных;
- $\text{Recall}@K$ — доля релевантных пользователей, которые удалось рекомендовать;
- MRR (Mean Reciprocal Rank) — учитывает позицию первого релевантного объекта в списке;
- NDCG — нормированная кумулятивная дисконтированная полезность, учитывающая ранжирование;
- Coverage — доля пользователей, которым система способна выдать хотя бы одну осмысленную рекомендацию. Высокий coverage свидетельствует о способности системы охватывать широкую аудиторию.

Оффлайн-оценка обычно проводится по схеме *leave-one-out*, когда одна

интеракция пользователя исключается из тренировочного множества и используется для тестирования [26].

После внедрения системы важно отслеживать эффективность рекомендаций по поведенческим метрикам в режиме онлайн. Наиболее информативные из них:

1. Доля взаимных лайков среди выданных рекомендаций;
2. Конверсия в диалог — отношение числа начатых чатов к количеству рекомендованных профилей;
3. Среднее время до первого взаимодействия (лайка или сообщения);
4. Удержание пользователей — как долго и регулярно пользователь взаимодействует с рекомендованными контактами;
5. Повторные взаимодействия — оценивается, продолжается ли активность с рекомендованным пользователем спустя время.

Помимо точности, важно учитывать качественные характеристики системы, которые напрямую влияют на пользовательское восприятие и вовлечённость:

- Разнообразие — рекомендации не должны быть однотипными;
- Новизна — включение ранее не встречавшихся кандидатов повышает интерес;
- Персонализация — учёт индивидуальных особенностей конкретного пользователя;
- Равномерность — отсутствие систематического перекоса в сторону ограниченной группы пользователей.

Для оценки рекомендательной системы в приложении знакомств важно сочетать количественные метрики точности и охвата с показателями пользовательского поведения. Такой подход позволяет обеспечить релевантность, персонализацию и устойчивую вовлечённость аудитории.

3 Теоретические основы разработки мобильных приложений

3.1 Общие особенности мобильной разработки

Мобильные приложения функционируют в условиях, отличающихся от настольной или серверной среды. Эти отличия накладывают определённые ограничения и формируют особые требования к проектированию, реализации и тестированию.

Во-первых, мобильные устройства имеют ограниченные ресурсы. Смартфоны и планшеты уступают настольным системам по вычислительной мощности, объёму оперативной памяти и возможностям хранения данных. Кроме того, приложения должны быть чувствительны к расходу батареи, особенно при активном использовании мультимедиа, анимации и фоновых процессов.

Во-вторых, в экосистеме мобильных устройств наблюдается значительное разнообразие. Существует множество моделей устройств с различными размерами экранов, плотностью пикселей, аппаратными возможностями и версиями операционных систем. Это требует особого внимания к адаптивности интерфейса и совместимости приложения с широким спектром устройств.

Помимо технических ограничений, важным аспектом является пользовательский опыт. Пользователи ожидают от приложения высокой скорости отклика, визуальной плавности и интуитивной структуры. Низкое качество интерфейса или перегруженность функциональностью могут привести к отказу от использования, независимо от пользы приложения.

Среди ключевых особенностей мобильной разработки можно выделить:

- ограниченные вычислительные ресурсы устройства;
- требования к экономии энергии и управлению фоновыми задачами;
- разнообразие устройств, экранов и версий операционных систем;
- необходимость обеспечения высокого уровня интерактивности и отзывчивости интерфейса;
- ориентация на кратковременные, но частые сценарии использования.

Эти особенности определяют специфику проектирования мобильных решений. Для успешной реализации приложения разработчику необходимо соблюдать ряд принципов, направленных на обеспечение стабильности, производительности и удобства использования [27].

К таким принципам относятся:

1. адаптация пользовательского интерфейса под различные размеры и ори-

- ентации экранов;
- 2. минимизация использования ресурсов устройства;
- 3. соблюдение рекомендаций по дизайну, принятых в целевой платформе;
- 4. обеспечение плавной и предсказуемой навигации по приложению;
- 5. проведение тестирования на разных устройствах и версиях операционной системы.

Таким образом, мобильная разработка представляет собой область, требующую сочетания инженерной дисциплины, внимания к деталям и ориентации на пользовательский опыт. Эти аспекты определяют основу архитектурных и технологических решений в мобильных системах.

3.2 Общие подходы к проектированию мобильных систем

Проектирование мобильных приложений требует системного подхода, включающего выбор архитектурной модели, структурирование компонентов и определение принципов взаимодействия между ними. Эти решения оказывают значительное влияние на надёжность, масштабируемость и удобство сопровождения системы.

К числу ключевых факторов, влияющих на архитектуру мобильного приложения, относятся:

- целевая платформа (Android, iOS или обе);
- требования к производительности и времени отклика;
- предполагаемый объём пользовательского трафика и сценарии нагрузки;
- организационные ограничения (время, бюджет, ресурсы);
- ожидаемая эволюция проекта и возможность масштабирования.

Современные мобильные приложения обычно строятся как распределённые системы, в которых клиент и сервер выполняют разные роли. Распространённые архитектурные подходы включают:

- монолитную архитектуру с полной локальной логикой (редко применяется в современных системах);
- клиент-серверную архитектуру с разделением обязанностей между устройством пользователя и серверной частью;
- модульную или микросервисную архитектуру, обеспечивающую масштабируемость и гибкость.

При этом важную роль играет концепция разделения ответственности: пользовательский интерфейс, бизнес-логика и работа с данными разносятся

по разным слоям приложения. Это способствует улучшению тестируемости, повторному использованию компонентов и упрощению сопровождения [28].

Независимо от конкретной реализации, архитектура мобильной системы должна обеспечивать:

1. слабую связанность между модулями;
2. чёткие границы между слоями;
3. стандартизированное взаимодействие между компонентами (например, через REST API);
4. возможность независимого обновления и масштабирования подсистем.

Такой подход обеспечивает устойчивую основу для развития и поддержки мобильного приложения в условиях изменяющихся требований и роста нагрузки.

3.3 Клиент-серверная архитектура

Клиент-серверная архитектура является одним из наиболее устойчивых и широко применяемых подходов при построении современных мобильных приложений. Её основным принципом является логическое разделение системы на два взаимосвязанных компонента: клиентскую часть, работающую на пользовательском устройстве, и серверную часть, выполняющую обработку запросов, управление данными и реализацию бизнес-логики.

Данный архитектурный подход обеспечивает целый ряд преимуществ:

- централизованное управление и консистентность данных;
- разгрузка клиентской части за счёт переноса вычислений на сервер;
- возможность переиспользования серверной логики в различных клиентских интерфейсах (веб, мобильных и пр.);
- упрощение обновления клиентских приложений без необходимости модификации серверного кода;
- гибкость масштабирования и балансировки нагрузки на стороне сервера.

Роль клиентской части заключается в следующем:

- предоставление пользовательского интерфейса и взаимодействие с пользователем;
- сбор и первичная обработка пользовательских данных;
- формирование сетевых запросов и обработка полученных ответов;
- управление локальным состоянием приложения и навигацией.

Серверная часть, в свою очередь, обеспечивает:

- централизованное хранение и обработку данных;
- реализацию бизнес-правил и логики приложения;
- аутентификацию и авторизацию пользователей;
- взаимодействие с внешними сервисами;
- логирование, мониторинг и обеспечение безопасности.

Взаимодействие между клиентом и сервером, как правило, осуществляется через стандартизированные протоколы (например, HTTP) и форматы обмена данными (чаще всего JSON или XML). Такой подход обеспечивает платформо-независимость и простоту интеграции.

Для реализации клиентской части всё более широкое распространение получают кроссплатформенные фреймворки, такие как Flutter. Он позволяет разрабатывать приложения с единой кодовой базой, сохраняя при этом высокую производительность и выразительность интерфейса.

Серверная логика зачастую реализуется с использованием зрелых и гибких платформ, таких как Spring, обеспечивающих поддержку REST API, управление транзакциями, безопасность и масштабируемость [29].

Таким образом, клиент-серверная архитектура остаётся актуальной и надёжной основой для построения мобильных систем, сочетающих в себе адаптивность, расширяемость и удобство сопровождения.

3.4 Безопасность и конфиденциальность

В современных мобильных приложениях вопросы безопасности и конфиденциальности данных занимают центральное место. Пользователи ожидают, что их личная информация будет защищена от несанкционированного доступа, утечки или подмены. Это особенно актуально для приложений, обрабатывающих чувствительные персональные данные, включая профили пользователей, переписку, предпочтения и другую информацию личного характера.

Обеспечение безопасности требует комплексного подхода, охватывающего как клиентскую, так и серверную часть приложения. В числе ключевых задач:

- защита канала передачи данных от перехвата и модификации;
- надёжная аутентификация и авторизация пользователей;
- контроль доступа к защищённым ресурсам;
- предотвращение распространённых уязвимостей (включая XSS, CSRF, SQL-инъекции и другие);
- обеспечение целостности и актуальности пользовательской сессии;

- соблюдение требований к обработке и хранению персональных данных.

Одной из стандартных практик является реализация авторизации на основе токенов. Наиболее распространённым решением в этом направлении являются компактные самодостаточные токены, которые позволяют хранить информацию о пользователе и его правах доступа в зашифрованном или подписанном виде. Использование токенов удобно в распределённых системах и облегчает реализацию масштабируемой безсессионной архитектуры [30].

Для защиты пользовательских данных от перехвата при передаче, общепринятым стандартом является использование защищённых транспортных протоколов. В частности, применяется HTTPS, основанный на TLS, который обеспечивает шифрование и аутентификацию соединения между клиентом и сервером.

На серверной стороне безопасность реализуется посредством встроенных или внешних фреймворков, позволяющих централизованно управлять доступом, разграничивать привилегии и применять политики безопасности. Такие решения также обеспечивают:

- предварительную фильтрацию входящих запросов;
- управление сессиями или токенами;
- обработку исключений, связанных с неавторизованным доступом;
- регистрацию действий пользователей для целей аудита.

С точки зрения пользовательского опыта и доверия, защита конфиденциальности является неотъемлемой частью проектирования. Приложение должно обеспечивать безопасное хранение пользовательских данных, возможность их удаления, а также отказоустойчивость в случае попыток несанкционированного доступа [31].

На практике к задачам обеспечения безопасности подходят с учётом принципов минимизации данных, разделения ответственности и поэтапного усиления контроля. Это позволяет проектировать надёжные и устойчивые к угрозам системы, соответствующие современным ожиданиям и требованиям.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- 1 Wang, X. Data scarcity in recommendation systems: A survey / X. Wang, Y. Liu, M. Chen at al. // arXiv preprint arXiv:2312.10073. — 2023.
- 2 Jin, D. A survey on fairness-aware recommender systems / D. Jin, L. Wang, H. Zhang, Y. Zheng, W. Ding, F. Xia, S. Pan // arXiv preprint arXiv:2306.00403. — 2023.
- 3 Jablons, Z. Large-scale collaborative filtering to predict who on okcupid will like you, with jax [Электронный ресурс] / Z. Jablons // OkCupid Tech Blog. — 2021. — URL: <https://tech.okcupid.com/large-scale-collaborative-filtering-to-predict-who-on-okcupid-will-like-you-with-jax-8> (Дата обращения 30.04.2025). Загл. с экр. Яз. англ.
- 4 Carman, A. Finding love on a first data: Matching algorithms in online dating [Электронный ресурс] / A. Carman // Harvard Data Science Review. — 2021. — URL: <https://hdsr.mitpress.mit.edu/pub/i4eb4e8b> (Дата обращения 30.04.2025). Загл. с экр. Яз. англ.
- 5 Tinder Engineering Team,. Personalized user recommendations at tinder [Электронный ресурс] // Proceedings of the Machine Learning Conference). — San Francisco, USA: 2017. — URL: <https://mlconf.com/sessions/personalized-user-recommendations-at-tinder-the-t/> (Дата обращения 30.04.2025). Загл. с экр. Яз. англ.
- 6 Zhao, Z. Weizhi zhang and yuanchen bei and liangwei yang and henry peng zou / Z. Zhao, W. Fan, J. Li at al. // arXiv preprint arXiv:2501.01945. — 2025.
- 7 Zhou, Z. Contrastive collaborative filtering for cold-start item recommendation / Z. Zhou, L. Zhang, N. Yang // arXiv preprint arXiv:2302.02151. — 2023.
- 8 Rudder, C. Okcupid: The math behind online dating [Электронный ресурс] / C. Rudder // AMS Graduate Student Blog. — 2013. — URL: <https://blogs.ams.org/mathgradblog/2016/06/08/okcupid-math-online-dating/> (Дата обращения 30.04.2025). Загл. с экр. Яз. англ.
- 9 Tinder,. Powering tinder — the method behind our matching [Электронный ресурс]. — 2022. — URL: <https://www.help.tinder.com/hc/en-us/articles/7606685697037-Powering-Tinder-The-Method-Behind-Our-Matching4> (Дата обращения 30.04.2025). Загл. с экр. Яз. англ.

- 10 Resnick, B. The tinder algorithm, explained [Электронный ресурс] / B. Resnick // Vox. — 2019. — URL: <https://www.vox.com/2019/2/7/18210998/tinder-algorithm-swiping-tips-dating-app-science> (Дата обращения 30.04.2025). Загл. с экр. Яз. англ.
- 11 Wells, G. Hinge founder justin mcleod explains how the algorithm finds your match [Электронный ресурс] / G. Wells // Fortune. — 2024. — URL: <https://fortune.com/2024/01/18/hinge-ceo-justin-mcleod-interview-attractiveness-score-algorithm-rose-jail/> (Дата обращения 30.04.2025). Загл. с экр. Яз. англ.
- 12 Relationstips,. How eharmony matches are made: Inside the algorithm [Электронный ресурс] / Relationstips. — 2025. — URL: <https://www.relationstips.com/how-eharmony-matches-are-made-inside-the-algorithm/> (Дата обращения 30.04.2025). Загл. с экр. Яз. англ.
- 13 Sugahara, K. Hierarchical matrix factorization for interpretable collaborative filtering / K. Sugahara, K. Okamoto // arXiv preprint arXiv:2311.13277. — 2023.
- 14 Lops, P. Content-based recommender systems: State of the art and trends / P. Lops, M. d. Gemmis, G. Semeraro // Recommender Systems Handbook. — 2011. — Pp. 73–105.
- 15 Zhang, S. Deep learning based recommender system: A survey and new perspectives / S. Zhang, L. Yao, A. Sun, Y. Tay // ACM Computing Surveys (CSUR). — 2019. — Vol. 52, no. 1. — Pp. 1–38.
- 16 Nabil, S. Demographic information combined with collaborative filtering for an efficient recommendation system / S. Nabil, M. Y. Chkouri, J. El Bouhdidi // International Journal of Electrical and Computer Engineering (IJECE). — 2024. — Vol. 14, no. 5. — Pp. 5916–5925.
- 17 Beregovskaya, I. Review of clustering-based recommender systems / I. Beregovskaya, M. Koroteev // arXiv preprint arXiv:2109.12839. — 2021.
- 18 Nadimi-Shahraki, M. H. Cold-start problem in collaborative recommender systems: Efficient methods based on ask-to-rate technique / M. H. Nadimi-Shahraki, M. Bahadorpour // Journal of Computing and Information Technology. — 2014. — Vol. 22, no. 2. — Pp. 105–113.

- 19 Xiangnan, H. Neural collaborative filtering / H. Xiangnan, L. Liao, H. Zhang, L. Nie, X. Hu, T.-S. Chua // arXiv preprint arXiv:1708.05031. — 2017.
- 20 Hidasi, B. Session-based recommendations with recurrent neural networks / B. Hidasi, A. Karatzoglou, L. Baltrunas, D. Tik // arXiv preprint arXiv:1511.06939. — 2016.
- 21 Kang, W. Self-attentive sequential recommendation / W. Kang, J. J. McAuley // arXiv preprint arXiv:1808.09781. — 2018.
- 22 van den Berg, R. Graph convolutional matrix completion / R. van den Berg, T. Kipf, M. Welling // arXiv preprint arXiv:1706.02263. — 2017.
- 23 Ruining, H. Visual bayesian personalized ranking from implicit feedback / H. Ruining, J. McAuley // arXiv preprint arXiv:1510.01784. — 2015.
- 24 Cano, E. Hybrid recommender systems: A systematic literature review / E. Cano, M. Morisio // Intelligent Data Analysis. — 2017. — Vol. 21, no. 6. — 1487–1524 p.
- 25 Guo, H. Deepfm: A factorization-machine based neural network for ctr prediction / H. Guo, R. Tang, Y. Ye, Z. Li, X. He // arXiv preprint arXiv:1703.04247. — 2017.
- 26 Recommender model evaluation: Offline vs. online [Электронный ресурс] // Shaped Blog. — 2023. — URL: <https://www.shaped.ai/blog/evaluating-recommender-models-offline-vs-online-evaluation> (Дата обращения 30.04.2025). Загл. с экр. Яз. англ.
- 27 Verma, R. Mobile app performance optimization - how it works and more? [Электронный ресурс] / R. Verma // Bacancy Technology. — 2024. — URL: <https://www.bacancytechnology.com/blog/mobile-app-performance> (Дата обращения 30.04.2025). Загл. с экр. Яз. англ.
- 28 Dhaduk, H. Mobile application architecture: Layers, types, principles, factors / H. Dhaduk // Simform Blog. — 2024. — URL: <https://www.simform.com/blog/mobile-application-architecture/> (Дата обращения 30.04.2025). Загл. с экр. Яз. англ.
- 29 Client-server architecture – system design [Электронный ресурс] // GeeksforGeeks. — 2024. — URL: <https://www.geeksforgeeks.org/>

client-server-architecture-system-design/ (Дата обращения 30.04.2025).
Загл. с экр. Яз. англ.

- 30 Best practices - oauth for mobile apps // Curity. — 2025. — URL: <https://curity.io/resources/learn/oauth-for-mobile-apps-best-practices/> (Дата обращения 30.04.2025). Загл. с экр. Яз. англ.
- 31 Zinkus, M. Data security on mobile devices: Current state of the art, open problems, and proposed solutions / M. Zinkus, T. M. Jois, M. Green // arXiv preprint arXiv:2105.12613. — 2021.